J方向初步可行性测试

任务：判断图片是真实还是AI生成，并检查训练中未见生成器上的表现。

目前能得出的判断

本机可以低成本跑通；跨生成器泛化仍是主要难点。普通基线在SD1.5上表现较好，换成BigGAN、ADM后接近随机水平。简单增强没有带来一致改善。J值得进一步探索，但这轮结果还不能支持质量门控方案有效。

这次具体测了什么

从第三方Tiny-GenImage的4个固定分片中取样，共1,200张。冻结CLIP ViT-B/32，提取512维特征，仅训练线性分类头。数据划分如下；BigGAN、ADM不参与训练或阈值选择。

分区	真实图	SD1.5	BigGAN	ADM
训练	300	300	0	0
验证	100	100	0	0
开发检查	100	100	100	100

每个开发比较为100张真实图＋100张对应生成图，三个比较共享真实池。先统一RGB和224×224裁剪，再施加变换；普通训练只用原图，增强训练使用原图、JPEG Q70和0.5倍缩放后还原三种视图。

实测结果：AUROC

训练方式	开发检查生成器	原图	JPEG Q50	0.5倍缩放
普通训练	SD1.5（已见）	0.9669	0.8803	0.9445
普通训练	BigGAN（未见）	0.4709	0.3975	0.4881
普通训练	ADM（未见）	0.5596	0.3349	0.5626
增强训练	SD1.5（已见）	0.9404	0.8899	0.9368
增强训练	BigGAN（未见）	0.4773	0.3581	0.4690
增强训练	ADM（未见）	0.4199	0.3112	0.4470

AUROC衡量真假得分的区分排序，越高越好，0.5为随机水平；它不是准确率。低于0.5表示在当前得分方向上出现反向排序，不能看完开发标签后翻转分数，再当作泛化成功。

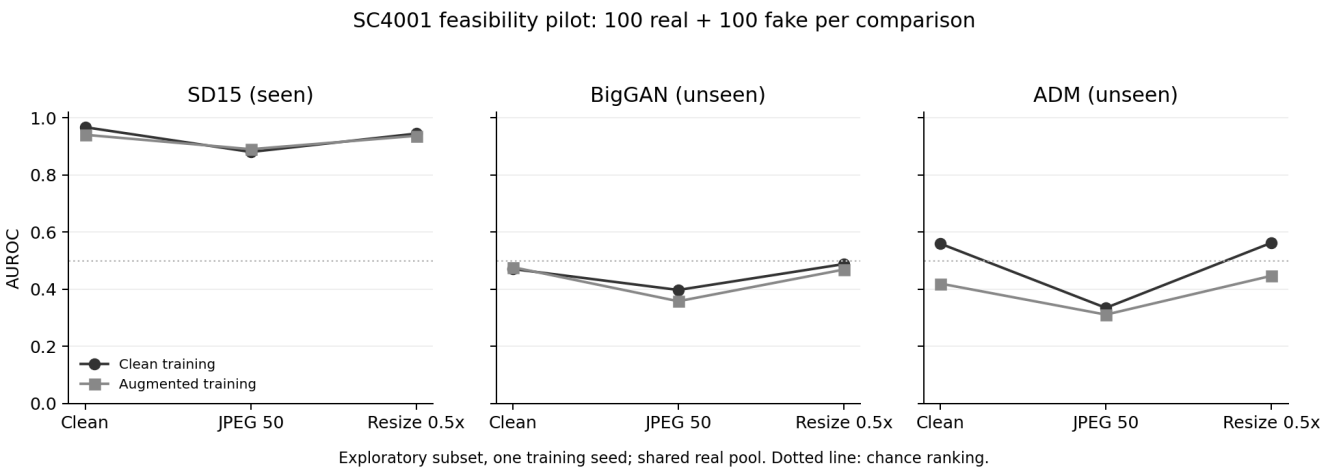
普通训练 / 原图的95%自助法区间：SD15 0.946 – 0.985；BigGAN 0.397 – 0.554；ADM 0.482 – 0.644。区间基于每格500次分层重采样，只描述本子集的抽样不确定性。

本机成本与核对

RTX 4050（6GB）；正式特征提取与训练评估共**64.4秒**，其中特征提取48.1秒；不含下载、环境配置与数据准备。36组指标均已从逐图预测文件独立重算，结果一致。

结果怎么理解，下一步讨论什么

这轮验证了实施可行性，并暴露了泛化与数据控制问题。



数据偏差：不能把高分直接当成生成痕迹

仅用原始宽高训练分类器，在SD1.5原图上就得到**0.9100 AUROC**。所选真实图全部源自JPEG、尺寸多样；SD1.5全部为512×512 PNG，BigGAN为128×128 PNG，ADM为256×256 PNG。

CLIP分支没有接收原始尺寸或文件名；上述结果提示数据混杂，不能据此认定CLIP具体用了哪种线索。统一输入尺寸、转存PNG，也不能消除原来的压缩、分辨率与重采样历史。

本轮结论的边界

样本来自固定4个第三方分片，仅一个训练种子；生成器标签未逐张独立认证。划分前剔除了2张近重复候选，但不能保证内容独立。三组比较共享真实图，不能当成完全独立的三次实验。

BigGAN、ADM结果已被查看，后续只能作为开发参考；最终实验需另留未用于选择方法的生成器 / 样本。此次未训练质量门控，也不是UnivFD论文ViT-L/14设置的严格复现。

建议下一轮的小范围验证

1. 先控制数据处理差异。对真假图对称施加统一的缩放与重编码规则，再检查尺寸 / 质量诊断和检测结果；保留对原有处理痕迹的限制说明。

2. 增加一个训练生成器。用同样的CLIP与线性头，比较单生成器和双生成器训练，控制训练总量，并保留开发生成器，观察泛化掉分是否缓解。

3. 再判断要不要做融合。先检查全局与局部分支是否互补，再决定是否投入质量感知门控。当前表格没有提供门控收益的证据。

群里建议先讨论

是否继续选J，并把下一轮目标定为“先改善跨生成器泛化、控制数据偏差”？如果继续，可先分工做数据核查和双生成器基线，暂缓扩展模型。以上是建议，尚未执行。

证据：results中的样本清单、逐图预测、指标及核对记录；实验代码版本7e425dc。
来源：Tiny-GenImage数据卡；UnivFD参考实现；项目私有仓库。代码执行与报告整理使用Codex辅助。